

로봇 양팔을 위한 에고센트릭 인간 시연

제2부: 단일 팔 큐브 접근(Approach)

Jeong Hwan Lee

기술 보고서, 버전 4, 2026년 10월 7일 alnrg2arg@gmail.com

요약본. 제1부는 큐브 삼단 쌓기를 다룹니다. 코드, 결과, 샘플 데이터는 요청 시 제공합니다.

Abstract—전이 가능한 가장 단순한 행동, 즉 에고센트릭 인간 시연만으로 학습한 오른팔의 빨간 큐브 접근을 따로 떼어 다룬다. 이러한 느린 동작에서는 IMU 시각-관성 스케일이 관측 불가능하므로, 스케일은 3.8cm 큐브 또는 테이블 원점에서의 테이블 평면으로부터 얻는다. 공유 작업 좌표계, 로봇 손목 핸드-아이 보정(0.16 px RMS), 로봇 카메라 렌더링을 통해 인간 레이블을 로봇 좌표계에 놓는다. 80–150개 테이크로 학습한 모델은 첫 체크포인트부터 과적합한다. 로봇 실행에서는 정지 사유만 기록되고 결과는 기록되지 않았으므로 성공률은 보고하지 않는다.

I. 실험 구성

작업자는 오른손에 HandUMI [1] 한 대(손목 어안 카메라, IMU, 조 엔코더)를 착용하며, 손목 자세는 MAST3R-SLAM [2]에서 얻는다(제1부). 레이블은 제1부의 데카르트 제약(50.05 ms 간격의 상대 자세 16개, 15 Hz 행)을 따른다. 왼팔과 그리퍼는 더미로서 손실에서 마스킹되므로 20차원 중 9차원만 지도된다. 모델은 X-VLA (0.9B) [3]이며 제1부의 레시피(소프트 프롬프트 슬롯 20, 배치 8, 8-bit AdamW, bf16)로 RTX 4090에서 학습한다. 로봇은 손목 C922가 달린 reBot B601 오른팔이며, 배포 중에는 왼팔과 양쪽 조를 잠근다.

II. IMU 없이 얻는 미터 스케일

HRA_red. 10월 3일 “빨간 큐브에 접근” 테이크 200개(10s)를 녹화했다. 에피소드별 IMU 스케일은 중앙값이 0.012이고 95개 테이크에서 0 또는 음수이다(그림 1b). 느린 접근은 가속도계를 충분히 자극하지 못한다. **큐브 PnP.** 정지한 큐브(모서리 3.8cm)를 2면/3면 모델 또는 정면에 가까운 단일 면 모델로 피팅하고, 큐브가 움직이지 않는다는 조건으로부터 궤적 스케일을 닫힌 형태로 구한다. IMU를 신뢰할 수 있는 양손 HRL80 테이크에서는 57개 중 37개가 PnP 유효이며 PnP/IMU 비는 1.062(p16–p84 0.959–1.274; 그림 1a)이다. 스케일 게이트와 타당성 게이트를 거쳐 200개 중 166개 테이크가 남는다(학습 151개, 20,319행; 검증 15개). 스케일 중앙값은 0.354(p5 0.188, p95 0.500), 큐브 중심 잔차는 0.17cm이다.

III. 인간 데이터를 로봇 좌표계에 놓기

로봇 보정. 헤드 C922를 체커보드로 보정하고(RMS 1.05 px), 보드 모서리를 터치하여 로봇 베이스에서의 위치를 구했다. 로봇 손목 카메라의 핸드-아이 보정(뷰 13장, 0.16 px RMS)에 따르면 카메라는 TCP보다 169.5mm 뒤에 있으며, 광축은 TCP x 축보다 33° 아래를 향한다. IK 스택의 TCP는 실제 조 끝단보다 약 82mm 앞에 있다. 이제 접근은 URDF 손끝 박스로 판정하며, 이전의 “끝단이 테이블 아래로 내려간다”는 판독은 이 인공물 때문이었으며

TABLE I

체크포인트별 held-out 손실(마스킹된 MSE). 괄호 안은 학습 부분집합 손실.

데이터(검증 테이크)	첫 체크포인트	중간	마지막 평가
HRA_red v1 (15)	15k: 0.150 (0.066)	30k: 0.198	105k: 0.299 (0.018)
A100, 시작점 기준 (11)	5k: 0.124 (0.110)	30k: 0.141	50k: 0.224 (0.020)
A100, 원점 기준 (11)	5k: 0.132 (0.097)	30k: 0.174	45k: 0.190 (0.022)

로 철회했다. HRA_red 테이크를 헤드 카메라를 통해 사후에 베이스와 연결한 결과는 166개 중 64개에 그쳤고 높이가 센티미터 단위로 퍼졌으며, 내보낸 카메라-IMU 외부 파라미터의 18° 오류가 드러났다.

로봇 카메라 렌더링(v2). v1은 추정된 카메라(화각 62–70°)로 손목 뷰를 렌더링했다. v2는 실측한 로봇 카메라(52°)와 핸드-아이 자세를 사용하고, 레이블을 로봇 TCP 자세로 표현한다.

공유 원점(HRA_A100). 각 테이크는 로봇 조 끝단도 터치했던 테이블 십자 위에 HandUMI 조 끝단을 2s 동안 대는 것으로 시작하며, 이어 3s 동안 로봇과 비슷한 시작 자세로 옮기고 10s 동안 접근한다. 테이블 선 위의 로봇 터치 세 점이 작업 좌표계 G 를 정의한다(60.4mm에 걸쳐 0.38mm 이내로 공선, 테이블은 $z = -27.1$ mm). 원점에서는 첫 MAST3R 포인트맵의 테이블 평면이 두 번째 스케일 원천이 되며(큐브 PnP 대비 비 0.999, 테이크별 오차 p50 8%, p90 37%), 원점 yaw는 테이크마다 측정한다(오차 p50 0.21°). 10월 6일 107개 테이크를 확보했다. 테이블 인지 변환(손끝 하한은 테이블 + 5mm, 끝점 들어올림은 최대 30mm)은 86개를 유지하며(CT5/CT6), 손끝 여유는 p50 12.6mm, 최소 7.6mm이다.

IV. 학습

모든 실행은 처음 평가한 체크포인트부터 과적합하며(표 I), v1 300k 실행은 학습 손실 0.002로 끝났다. 상태의 기준을 테이크 시작점에 두든 원점에 두든 held-out 손실에는 차이가 없다. 이 글을 쓰는 시점에는 10월 6일 채택 테이크 85개와 선택한 로봇 시작 자세를 사용한 실행(CT7)이 진행 중이었다.

V. 로봇 실행과 배포

v1은 가까운 시작점에서는 큐브를 향해 움직였고, 먼 큐브에 대해서는 테이블 위를 끌며 이동했다(두 번의 실행에서 각각 약 39cm, 26cm). 10월 7일 작업자가 팔이 큐브를 미는 것을 관찰하여, 이제 인터페이스는 손목 뷰에서 큐브의 겉보기 크기가 임계값을 넘으면 정지한다(근




Fig. 1. IMU와 큐브 PnP로 구한 테이크별 미터 스케일. (a) IMU를 신뢰할 수 있는 HRL80 쌓기 테이크. (b) HRA_red 접근 테이크: IMU 스케일이 0 주변에 흩어진다.

접 대리 지표이지 검증된 접촉이 아니다). 그날 127개 세션 중 69개가 이렇게 끝났다. 실행 설정은 체크포인트만큼 중요했다. 인터페이스 재시작으로 청크 블렌딩 파라미터가 조용히 초기화되자, 작업자는 값을 복원할 때까지 추론 품질이 “많이 낮아졌다”고 보고했다. 시행 결과는 기록되지 않았으므로 성공률은 없다.

VI. 교훈과 향후 과제

모든 스케일 원천은 어딘가에서 조용히 실패하므로(느린 동작에서의 IMU, 일부 테이크에서의 원점 평면) 독립적인 원천이 두 개 필요하다. 로봇과 공유하는 물리적 원점이 사후 정합보다 낫다. IK TCP는 규약일 뿐 손끝이 아니다. 작은 단일 작업 데이터셋은 즉시 과적합하므로 시험할 것은 이른 체크포인트이다. 실행 설정은 정책의 일부이다. 다음 단계는 고정된 시작 자세와 큐브 위치에서 설정을 고정한 채 시행을 기록하는 것, A, B, CT7의 이른 체크포인트를 시험하는 것, 렌더링 이미지의 큐브 색(학습에서는 주황색, 로봇에서는 빨간색)을 보정하는 것이다.

References

- [1] C. Chi *et al.*, “Universal manipulation interface,” in *RSS*, 2024.
- [2] R. Murai, E. Dexheimer, and A. J. Davison, “MASt3R-SLAM,” in *CVPR*, 2025.
- [3] J. Zheng *et al.*, “X-VLA: Soft-prompted transformer as scalable cross-embodiment VLA model,” in *ICLR*, 2026.